

哈 尔 滨 工 业 大 学

硕士学位论文开题报告

题 目：Two-tone 移位异或纠删码的高效实现研究

院	(系)	计算机科学与技术学院
学 科 / 专 业		计算机科学与技术
导 师		王强副教授
研 究 生		孙铎
学 号		24S051046
开题报告日期		2025 年 08 月 30 日

深圳校区教务部 制

目 录

第 1 章 课题的来源及研究目的和意义	1
1.1 课题来源	1
1.2 研究的目的和意义	2
第 2 章 国内外研究现状及分析	3
2.1 国内外研究现状	3
2.2 国内外文献综述及简析	3
2.2.1 RS 码相关研究分析	3
2.2.2 移位异或码相关研究分析	4
2.2.3 移位异或码相关研究分析	4
第 3 章 主要研究内容及研究方案	5
3.1 研究内容	5
3.1.1 存储编码的基本原理	5
3.1.2 Two-tone Shift-XOR 的编解码原理	6
3.1.3 优化问题描述	8
3.2 研究方案	8
3.2.1 统一解码抽象：Erasure-Parity Mapping	8
3.2.2 缓存友好的窗口划分：Cache-Friendly Window	11
3.2.3 内存友好的相邻合并访问：Neighbor-Merging Access	12
3.2.4 特化与泛化结合：Special Case Expansibility	13
第 4 章 预期目标	15
4.1 系统集成与应用目标	15
4.1.1 接口集成与功能验证	15
4.1.2 集群集成与应用验证	15
4.2 性能优化与方法论总结目标	15
第 5 章 已完成的研究工作及进度安排	17
5.1 已完成的研究工作	17
5.2 进度安排	17
第 6 章 已具备的研究条件和所需条件及经费	18
6.1 实验室条件和经费保障	18
6.2 所需条件及经费	18

第 7 章 预计困难及解决方案 19

7.1 预计困难与技术难点 19

7.2 解决方案 19

参考文献 20

第 1 章 课题的来源及研究目的和意义

1.1 课题来源

在现代存储系统中，数据可用性对于应对各种故障至关重要^[1]。目前，主流的容错技术包括数据复制和纠删码。数据复制通过在不同节点保存多份副本，虽然实现简单，但存储开销较大。例如，三副本机制能容忍两次故障，但需要三倍的存储空间。相比之下，纠删码技术能够以远低于复制的存储成本，提供同等甚至更高的数据可靠性^[2]。因此，纠删码已成为 Google 文件系统 (GFS)^[3]、Windows Azure 存储^[4,5]、Hadoop 分布式文件系统 (HDFS)^[6,7] 以及 Ceph^[8,9] 等大规模存储系统的重要技术。

纠删码通过对原始数据进行编码生成冗余校验信息，从而提升数据可靠性，并在数据丢失时实现恢复。与复制技术相比，经典纠删码 Reed-Solomon 码 (RS 码)^[10] 的编码和解码过程计算量更大^[2]，其通常依赖于有限域 $GF[2^w]$, $w > 1$ 上的矩阵乘法，并在计算时将部分有限域上的运算转换为异或运算 (亦即有限域 $GF[2]$ 上的运算)^[11]。众多研究如 Jerasure^[12,13]、G-CRS^[14]、Zerasure^[15,16]、SLPEC^[17]、Cerasure^[18,19] 和 Intel 的 ISA-L 库^[20] 等都致力于提升基于有限域矩阵乘法的编解码效率，以降低系统成本并增强服务可靠性。近年来，基于非循环移位异或运算的纠删码在理论层面取得许多进展，例如 ZigZag Decodable Codes^[21-23] 和 Two-tone Shift-XOR Codes^[24-28]，并且在存储^[23,29]、密码学^[30-32] 和网络^[33] 等应用领域进行了各种拓展研究。对于这类移位异或的编解码算法来说，异或运算就是最基本的运算，而并非像传统纠删码那样需要转化，这种更简单更直接的运算方式也取得了更高的理论性能^[23]。相比于 ZigZag 算法，Two-tone 算法对于移位和异或操作的编排更具有规则性，使得其在解码时无需多次扫描可解出数据的位置，更容易按顺序访问内存，在算法实现层面有更高效率的潜能^[27,28]。

尽管 Two-tone 纠删码在理论上具备优越性能，其完整的工程实现尚处于探索阶段。现有文献虽展示了算法潜力，但缺乏可用于生产环境的高性能实现。具体来讲，有以下三点问题：

- 缺少泛化性实现：当前的算法实现只能在实验测试中证明高效性，但并不具有泛化能力，无法应对所有的丢失情况，不能同时满足存储系统中解码丢失数据块和重新编码丢失校验块的双重需求。
- 缺少系统级优化：算法没有明确给出程序优化的策略，例如减少条件分支、增强缓存局部性和减轻内存访问压力等优化，而 RS 纠删码的系统优化策略因基本算法不同而无法直接应用到移位异或纠删码码上。

- 缺少工业级应用：上述纠删码研究成果仅有 Jerasure 和 ISA-L 等少数算法以插件的形式集成到 Ceph 和 Hadoop 等开源存储系统中，大部分算法的并没有在工业级应用的条件环境下测试并验证高效性。

基于上述三点问题，本课题将 Two-tone 移位异或纠删码以插件形式集成至开源分布式存储系统 Ceph 中，作为一种存储编码，借助 Ceph 中的应用规范对比测试纠删码算法，并在该应用场景下做系统级优化，提炼出针对于移位异或纠删码的高效实现方法论，说明各方法论的有效性，达成比 Ceph 中的 SOTA 纠删码插件和最新研究中的 SOTA 纠删码算法更高效的性能。

1.2 研究的目的和意义

本课题旨在设计并优化高效的 Two-tone 纠删码实现方案，推动新型移位异或纠删码算法在大规模分布式存储系统例如 Ceph 中的落地应用，实现比其他纠删码算法更优秀的应用性能。

本课题的研究目的主要在于以下三点：

- 将 Two-tone 移位异或纠删码以插件的形式集成至 Ceph 分布式存储系统中，通过完整的功能性测试，并部署至存储池加以应用。
- 针对 Two-tone 算法本身，提出系统级优化方法，检验各方法的有效性，提炼并总结适用于新型移位异或纠删码的优化方案。
- 实施性能对比实验，与 Ceph 中的 SOTA 纠删码 ISA 比较，与 RS 码的 SOTA 实现 Cerasure 和移位异或码的 SOAT 实现 ZigZag 比较，取得更高效的性能。

本课题的研究意义主要在于以下三点：

- 实现更高效的纠删码算法，进一步提高编解码吞吐量，促进解决纠删码吞吐量不匹配高性能设备的问题^[34]
- 推动移位异或纠删码从算法理论到实际应用，呈现新型高效纠删码解决方案。
- 填补移位异或纠删码缺少系统级优化方法论的空白，对齐 RS 码的研究进度，发挥出移位异或码的高效潜能。

第 2 章 国内外研究现状及分析

2.1 国内外研究现状

随着分布式存储系统的快速发展，纠删码作为容错和数据可靠性保障的核心技术，受到了广泛关注。传统的 Reed-Solomon (RS) 码^[10] 在理论和应用层面都取得了重要进展，其基于有限域的编码方式具有良好的 MDS（最大距离可分）特性，能够在任意丢失情况下恢复原始数据。为提升 RS 码的实际编解码效率，研究者们提出了多种优化策略，包括将有限域运算转化为异或运算（XOR-Based）^[11]，以及采用 Vandermonde 或 Cauchy 矩阵以减少逆运算开销^[35]。在程序实现层面，优化矩阵结构以减少异或操作数、提取并复用公共运算表达式、缓存管理和指针优化等技术不断涌现^[16,17,19]。例如，Zerasure、SLPEC 和 Cerasure 等库通过矩阵稀疏化、运算链优化和空间局部性提升，显著提高了编码吞吐量。

近年来，基于移位异或运算的新型纠删码逐渐成为研究热点。ZigZag Decodable Codes^[21,23] 通过构建特殊的移位矩阵，实现了仅依赖异或和移位操作的高效编码与解码，理论上可达到线性时间复杂度，并在存储、密码学和网络等领域得到拓展应用。Two-tone Shift-XOR Codes^[27,28] 进一步提升了移位异或码的结构规则性和解码效率，具备更低的存储开销和更高的吞吐性能。相关研究表明，Two-tone 编码在实际场景下可实现比 RS 码更高的编码和解码速度，尤其适用于高性能分布式存储系统。

2.2 国内外文献综述及简析

2.2.1 RS 码相关研究分析

RS 码作为经典的纠删码方案，最早由 Reed 和 Solomon 提出^[10]，其理论基础和 MDS 特性为后续编码技术奠定了坚实基础。Luby 等人提出了基于异或运算的优化方法^[11]，使得编码和解码过程更适合实时应用。随着硬件并行能力提升，Jerasure 库^[12,13] 和 G-CRS^[14] 等实现了多线程和 GPU 加速，但对硬件资源有较高要求。为进一步降低运算复杂度，研究者们通过优化编码矩阵结构（如 Cauchy 矩阵^[35]），减少矩阵中 1 的数量，进而减少异或操作数^[16,19]。此外，提取公共异或表达式并复用、缓存优化和指针管理等技术也被广泛应用于提升编码效率^[16,17]。Cerasure 库通过多维度优化，编码吞吐量较 SOTA 库提升显著^[19]。

2.2.2 移位异或码相关研究分析

移位异或码以其简单高效的运算方式成为纠错码领域的新兴方向。ZigZag Decodable Codes^[21,23] 通过构建特殊的移位矩阵，实现了仅依赖异或和移位操作的高效编码与解码，理论上可达到线性时间复杂度，并在存储、密码学和网络等领域得到拓展应用。Two-tone Shift-XOR Codes^[27,28] 进一步提升了移位异或码的结构规则性和解码效率，具备更低的存储开销和更高的吞吐性能。相关研究表明，Two-tone 编码在实际场景下可实现比 RS 码更高的编码和解码速度，尤其适用于高性能分布式存储系统。

与 RS 码不同，移位异或码的所有数据块均参与异或运算，避免了有限域上的复杂运算。由于移位量的多样性，难以提取公共表达式，且数据访问模式与传统纠错码不同，导致缓存和指针优化策略无法直接迁移。因此，针对移位异或码的系统级优化方法仍需进一步探索和完善。减少矩阵的 1 的个数进而减少运算数的工作有：Zerasure^[16]、^[35]、Cerasure^[19] 提取公共异或运算表达式并复用减少运算：Zerasure^[16]、SLPEC^[17] 缓存优化：Zerasure^[16]、SLPEC^[17] 数据指针开销降低：Cerasure^[19]

2.2.3 移位异或码相关研究分析

123^[21] ZigZag Decodable 理论：基于 vandermonde 构建移位矩阵并异或计算校验块，基于 Hankel 矩阵构建更高效^[23] 结合相关应用领域的拓展

Tow-tone 理论：RID、Shift-XOR elimination^[27]，进一步拓展出 Two-tone Elimination^[28] 形成 Two-tone 算法

无法直接应用 RS 码的系统优化策略到移位异或，因为移位异或是所有数据块都会参与异或，避免有限域上其他运算，不同的移位量也导致无公共表达式，偏移量计算方式不同以及数据访问模式不同无法直接应用缓存或指针开销优化

第 3 章 主要研究内容及研究方案

3.1 研究内容

3.1.1 存储编码的基本原理

纠删码是一类通过冗余编码提升数据可靠性的算法，可作为存储编码应用到存储系统中，相比于创建多个数据副本以防数据丢失，它通过数学算法将原始数据转换为带冗余信息的编码数据，在可靠性与存储效率间取得平衡，非常适用于大规模分布式存储场景。以最经典的 Reed-Solomon (RS) 码^[10] 为例，假设将原始数据均分成 k 个数据块，再同生成矩阵进行有限域上的矩阵乘法运算，编码出 m 个校验块，总计得到 $n = k + m$ 个块，并将这 n 个块分别存储到 n 台分布式的存储设备中，这样最多能容忍 m 块数据丢失，即 m 台设备故障。RS 码的编码过程可由式 (3-1) 表示。

$$\mathbf{C} = \mathbf{G} \times_{GF[2^w]} \mathbf{D} \quad (3-1)$$

其中， $\mathbf{D}$ 为原始数据块向量， $\mathbf{G}$ 为生成矩阵（通常为 Vandermonde 或 Cauchy 矩阵^[11]）， $\mathbf{C}$ 为编码后的校验块向量。图3-1以 $k = 4, m = 3$ 为例，展示了 RS 码的编码过程。




图 3-1 RS 码编码举例

解码时，根据丢失数据块的情况，基于编码公式构造逆矩阵，得出新的解码公式，从而恢复丢失的数据块，再重新编码以恢复丢失的校验块，可由式 (3-2) 表示。

$$\mathbf{D} = \mathbf{G}'^{-1} \times_{GF[2^w]} \mathbf{D}' \quad (3-2)$$

其中， $\mathbf{D}'$ 为所有未丢失的数据块和校验块构成的向量， $\mathbf{G}'^{-1}$ 为根据丢失情况构造的逆生成矩阵， $\mathbf{D}$ 为原始数据块向量。图3-2举例展示了 RS 码的解码和重编码过程。




图 3-2 RS 码解码举例

3.1.2 Two-tone Shift-XOR 的编解码原理

Two-tone Shift-XOR 码是一种基于移位和异或操作的高效纠错码。其核心思想是利用规则的移位矩阵和异或运算实现编码与解码，避免有限域上的乘法运算，提升运算效率。Two-tone 码的编码过程可由式 (3-3) 表示。

$$\mathbf{C} = \mathbf{Z} \times \mathbf{D} \quad (3-3)$$

其中， $\mathbf{Z}$ 为移位生成矩阵，采用最简单且规则的 Two-tone 矩阵^[28]，其中每个元素 $z^{s_{ij}}$ 代表偏移量。假设原始数据块分别为 $\{D_1, D_2, \dots, D_k\}$ ，编码后得到的校验块分别为 $\{C_1, C_2, \dots, C_m\}$ ，则 Two-tone 的编码公式还可以表示为式 (3-4)。

$$C_i = \bigoplus_{j=1}^k z^{s_{ij}} D_j \quad (3-4)$$

其中 $z^{s_{ij}} D_j$ 表示对数据块 D_j 进行 s_{ij} 个单位的非循环移位， $\oplus$ 为异或操作。图3-3举例展示了 RS 码的编码过程。




图 3-3 Two-tone 码编码举例

Two-tone 算法的移位生成矩阵具有规则结构，使得解码时可以自然按序逐步解出丢失块，提升解码效率。图3-4举例展示了 Two-tone 码在丢失三个数据块时的解码过程，总体分成两步，第一步是“代入”，将未丢失的数据块代入至校验块中，第二步即为“Two-tone 消除”，每一轮次中，从一边最外侧错开的单位开始，依次向内解出每个单位，直到无法再求解，再从另一边最外侧错开的单位开始，依次向内求解，直到解出该轮次内的所有单位，再进入下一轮，循环解出所有数据。解出的单位要代入至校验块，以便后续继续解出其他单位。这里提到的“一边”和“另一边”，即对应 Two-tone 算法中的两个子系统^[28]，按序求解这两个子系统，即可高效解出所有数据。

图3-5举例展示了 Two-tone 码在丢失两个数据块和一个校验块时的解码过程，不同之处在于，只有一边有错开的单位，相当于两个子系统的其中一个为空集，无




图 3-4 Two-tone 码丢失 3 个数据块的解码举例

需进行操作，其他流程不变即可。本例中由于出现了校验块的丢失，在解码完成后，还需要重新编码丢失的校验块，这样才算完成了全部要求。

3.1.3 优化问题描述

尽管 Two-tone Shift-XOR 码在理论上具备高效性，但实际工程实现仍面临如下优化问题：

- 如何统一处理所有丢失情况，实现解码和重编码的泛化，兼顾高效性；
- 如何提升缓存局部性，减少内存访问压力，缓解算法整体的内存瓶颈；
- 如何针对只丢失一块的常见场景进一步特化优化，发挥硬件指令优势。

基于此，本课题给出了一系列研究方案。

3.2 研究方案

3.2.1 统一解码抽象：Erasure-Parity Mapping

对于不使用特殊抽象方法的解码，在“代入”步骤时，需要判断校验块是否存在，才能确定是否要执行代入计算。在“消除”步骤时，每个丢失的数据块要按顺序匹配未丢失的校验块，从而按照前文所述的消除规则，从错开的单位开始解码，




图 3-5 Two-tone 码丢失 2 个数据块和 1 个校验块的解码举例

将解出的单位继续“代入”，进而解出完整的数据块。最后，还需要判断是否要重新编码丢失的校验块。图3-6展示了这种解码方式的总体流程。

针对多样化的丢失情况，本课题提出 Erasure-Parity Mapping 的解决方案。该方案将所有丢失块（包括数据块和校验块）统一抽象为 Erasure 结构，每个 Erasure 结构按块编号顺序匹配未丢失的校验块，若 Erasure 结构本就来源于丢失的校验块，则其匹配自己即可。在“代入”步骤时，无需额外判断，直接将未丢失的数据块代入 Erasure 结构即可。在“消除”步骤时，直接从已经匹配好的校验块中解出数据单位即可，将解出的单位同样直接“代入”到所有 Erasure 结构中。因为以上两个步骤是对所有 Erasure 结构的统一操作，而 Erasure 结构包括了所有丢失的数据块和校验块，所以数据块的解码和校验块的重编码可以互相穿插并同时完成，无需单独的重编码步骤，进一步减少了遍历与内存访问次数。

图3-7展示了 Erasure-Parity Mapping 解码方案的总体流程，算法3-1列出了该方案的伪代码实现，其中 D 为数据块指针数组， C 为校验块指针数组， Ed 为丢失的

数据块索引， Ec 为丢失的校验块索引， k 为数据块个数， m 为校验块个数，数据块和校验块依次从 0 到 $k + m - 1$ 编码。这种 Erasure 结构实现了解码流程的统一抽象，将同类操作统一进行，同时处理码字的解码与重编码，实现了简洁与高效。




图 3-6 Two-tone 一般解码实现流程




图 3-7 Erasure-Parity Mapping 统一解码实现流程

3.2.2 缓存友好的窗口划分：Cache-Friendly Window

在 Two-tone Shift-XOR 码的实际工程实现中，内存访问成为主要瓶颈。由于移位和异或操作本身极为高效，整体性能受限于数据块（chunk）在内存中的读写效率。尤其在大规模分布式存储系统中，频繁的内存访问会导致缓存失效，拖慢整体编解码速度。因此，提升缓存局部性成为优化的关键。

为此，提出了 Cache-Friendly Window 方案：将较长的数据块划分为更小的窗口（window），每次仅处理一个 window 的数据。这样可以显著提升数据在 CPU 缓存中的命中率，减少跨 chunk 的内存访问，缓解内存瓶颈。图3-8展示了该方案。同时，每个 window 独立初始化，并采用“首次访问时初始化”（Init On First Access）

算法 3-1 Two-tone Erasure-Parity Mapping 解码

Input: D, C , Ascendingly sorted Ed and Ec, k, m

Output: Recover all erased data and coding chunks

```

1 /* Step 1: Map erasures with parities */
2 for  $i \in Ec$  do
3   |  $map\_erasure\_ptr[i - k] \leftarrow C[i]$  init by 0
4 end
5 for  $i \in (\{k, \dots, k + m - 1\} - Ec)$  and  $!Ed.empty()$  do
6   |  $coding\_data\_map[i - k] \leftarrow Ed.pop\_front()$ 
7   |  $map\_erasure\_ptr[i - k] \leftarrow D[coding\_data\_map[i - k]]$  init by  $C[i - k]$ 
8 end
9 /* Step 2: Substitute available data into mapping erasures */
10 foreach non-null data chunk  $D[i]$  do
11   | foreach non-null  $map\_erasure\_ptr[j]$  do
12     | Shift-xor the slices of  $D[i]$  into  $map\_erasure\_ptr[j]$ 
13   | end
14 end
15 /* Step 3: Decode erased data and substitute it */
16 foreach non-null  $coding\_data\_map[i]$  do
17   | Decode the slice of  $D[coding\_data\_map[i]]$  from  $map\_erasure\_ptr[i]$ 
18   | foreach other non-null  $map\_erasure\_ptr[j]$  do
19     | Shift-xor the decoded slice into  $map\_erasure\_ptr[j]$ 
20   | end
21 end

```

策略。实际应用如 Ceph 等分布式存储系统，分配的 chunk 内存空间通常不会预先初始化，若一开始就对全部 chunk 进行初始化，开销极大且浪费。因此，结合 window 划分，只有在 window 被实际访问时才进行初始化，边操作边 init，极大提升了初始化效率和缓存利用率。

chunk size = 16, window size = 4, D1只代入第1个窗口，无法覆盖D2、D3和D4的第1个窗口
 解决方案：off-by-one window, D1领先代入1个窗口，即可覆盖，同时几乎不影响窗口局部性




图 3-8 Cache-Friendly Window 效果演示

在解码过程中，还需考虑 window 与解码流程的特殊关系。Two-tone 码的解码分为“代入”和“消除”两个步骤，不同块之间存在错位。若仅对当前 window 进行“代入”，可能导致解码位置的 window 未被完全覆盖，影响解码正确性。为此，提出 off-by-one 偏移策略：在“代入”时，窗口处理范围比“消除”领先一个 window 大小，即“代入”窗口始终覆盖“消除”窗口的全部数据。只需保证 window size 大于数据块个数 k ，即可实现完整覆盖。这一策略易于实现，既保证了缓存局部性，又确保了解码流程的正确性和高效性。图3-8也展示了这种处理方案。

3.2.3 内存友好的相邻合并访问：Neighbor-Merging Access

在 Two-tone Shift-XOR 码的实际编码过程中，数据块与校验块的一般访问模式可分为横向和纵向两种，如图3-9所示。横向模式是指每次遍历一个数据块，将该块内的所有数据单位依次异或到所有校验块的对应位置，然后再处理下一个数据块。这种方式对单个数据块的利用非常充分，能够集中地访问和处理数据块，但由于每个数据单位都要异或到所有校验块，导致对校验块的内存需要反复多次访问，且访问不集中，容易造成缓存失效。

纵向模式则是针对每个校验块进行处理。每次遍历一个校验块，根据该校验块的每个单位，去访问所有数据块的对应单位并进行异或计算。这样对于同一个校验块来说，只需访问一次即可完成全部计算，提升了校验块的访问效率。但由于不同校验块的移位偏移量不同，无法复用之前数据块异或的结果，导致对数据块的访问变得重复且不集中，影响整体效率。




图 3-9 Two-tone 编码横向与纵向访问模式

针对上述两种模式各自的内存访问瓶颈，提出了“相邻合并访问”（Neighbor-Merging Access）策略。该策略结合横向和纵向的优点，将相邻的两个数据块 chunk 的单位在寄存器中合并处理，利用 SIMD 指令或寄存器批量操作，总体上横向访问数据块，计算和访存时则先在寄存器内完成纵向合并运算，再一次性写入校验块内存。这样既能充分利用数据块的访问局部性，又能减少对校验块的重复访问，理论上可减少一半对校验块内存的重复访问，显著提升整体编码效率。

综上，Neighbor-Merging Access 模式通过横向与纵向访问的有机结合，实现了对数据块和校验块的高效利用，减少了内存的重复和不集中的访问，提升了 Two-tone Shift-XOR 码在实际工程中的编解码性能。

3.2.4 特化与泛化结合：Special Case Expansibility

在实际分布式存储系统中，多台设备同时故障的概率远低于单台设备故障，因此只丢失一块的场景极为常见。由于这种情况数较少且逻辑简单，针对其进行特化优化的开发成本很低。具体而言，当仅有一块数据或校验块丢失时，无需采用 Two-tone 码常规的两侧错位解码流程，只需将所有未丢失的 chunk 整体异或代入即可恢复丢失块，相当于仅执行“代入”步骤，且只需操作一个 Erasure 结构。如图3-11所示。这种特化流程不仅极大简化解码逻辑，还具备显著的加速潜力。由于只需访问一次所有 chunk，可以大胆采用 AVX2 等 SIMD 流指令，并利用 stream 命令绕过缓存，进一步提升解码效率。综上，针对单块丢失场景进行特化优化，能够在实际应用中获得极高的性能收益，且与泛化解码流程结合，实现全场景下的高效编解码方案。




图 3-10 Neighbor-Merging Access 模式




图 3-11 Two-tone 解码只丢失一块的特化情况举例

第 4 章 预期目标

4.1 系统集成与应用目标

当前大多数纠删码算法仅在自建测试环境或理论分析中验证性能，缺乏在工业级分布式存储系统中的实际集成和应用。为此，本课题将 Two-tone 移位异或纠删码以插件形式集成至 Ceph 分布式存储系统，推动新型高效纠删码技术在真实生产环境中的落地应用。系统集成目标分为两个层次：

4.1.1 接口集成与功能验证

首先，通过 Ceph 官方自带的纠删码接口，对 Two-tone 算法进行编码和解码的正确性及性能测试。该阶段重点在于利用 erasure-parity mapping 机制，确保算法能够应对所有可能的数据和校验块丢失情况，满足 Ceph 存储系统的基本应用要求。通过标准化接口测试，验证 Two-tone 算法在多样化擦除模式下的功能完整性和高效性。

4.1.2 集群集成与应用验证

进一步，利用 Ceph 官方自带的集群仿真脚本，建立分布式测试集群，采用自定义 Two-tone 纠删码创建存储池，并在存储池中完成文件的读写操作。该阶段不仅要求算法在单机环境下表现优异，更需在分布式系统中实现稳定可靠的读写流程，标志着 Two-tone 纠删码实现了真正意义上的系统级集成。通过实际应用场景的验证，确保算法具备工业级部署能力和扩展性。

4.2 性能优化与方法论总结目标

本课题预期通过提出并实现以下四项系统级优化策略，显著提升 Two-tone 编码和解码的吞吐量，降低内存访问瓶颈，并在实际应用中验证其有效性：

- **统一解码抽象 (Erasure-Parity Mapping)**：实现所有丢失情况的统一处理流程，提升解码和重编码的泛化能力与效率。
- **缓存友好窗口划分 (Cache-Friendly Window)**：通过窗口化处理和首次访问初始化，优化数据块的缓存局部性，减少内存访问开销。
- **内存友好相邻合并访问 (Neighbor-Merging Access)**：结合横向和纵向访问模式，合并数据块处理，减少对校验块的重复访问，提升整体编码效率。

- **特化优化 (Special Case Expansibility)**: 针对单块丢失等常见场景, 采用特化流程和硬件指令集加速, 实现极端场景下的高效解码。

上述优化策略的实现和验证是本课题的重要目标。通过与 Ceph 现有 SOTA 纠删码插件 (如 ISA-L、Cerasure、ZigZag) 进行性能对比, 全面评估各项优化措施的实际效果。最终, 课题将系统性总结基于移位异或的纠删码系统优化方法论, 填补这方面的空白, 为后续相关算法的工程实现和产业应用提供参考, 推动高效纠删码技术在分布式存储系统中的广泛应用。

第 5 章 已完成的研究工作及进度安排

5.1 已完成的研究工作

- 梳理并总结国内外纠删码相关理论与系统优化方法，完成文献调研。
- 分析 Two-tone 移位异或纠删码的算法原理，明确优化方向与技术难点。
- 初步设计 Two-tone 编码与解码的统一抽象结构，完成部分解码泛化功能的代码。
- 搭建 Ceph 分布式存储系统的测试环境，集成最简单的 Two-tone 算法实现作为插件，成功通过 Ceph 的纠删码接口测试。

5.2 进度安排

1. **2025.09-2025.10**: 继续深入调研相关文献，完善算法理论分析，尝试并明确优化方案。
2. **2025.10-2026.03**: 完整集成 Two-tone 纠删码插件至 Ceph 中，完成 Two-tone 编码与解码算法的高效实现，应用所有优化方案，做消融实验证明各方案有效性，做对比实验证明相较于其他纠删码的高效性。
3. **2026.03-2026.05**: 总结各优化方法论，总结实验成果，撰写论文。

第 6 章 已具备的研究条件和所需条件及经费

6.1 实验室条件和经费保障

实验室有可用于实验的单台服务器，具备 1TB 容量的 NVMe 磁盘，足够将 Ceph 测试集群单独运行，并进行 GB 级别的大文件读写测试。

6.2 所需条件及经费

Ceph 提供了在单台机器上模拟多节点并建立测试集群的功能，与常规多机分布式集群在功能上没有差别，方便做测试研究，也可直接测试纠删码吞吐量，因此无需额外的特殊条件与经费。

第 7 章 预计困难及解决方案

7.1 预计困难与技术难点

Ceph 项目庞大，纠删码接口未完全解释所有内容，可能有遗漏借鉴其他纠删码组织形式，解析测试脚本

大集群难以搭建，编译费时配置容器环境，利用官方 `vstart.sh` 虚拟集群，功能同样完善

不允许更长校验块内存数据库 `redis` 存储多余块

泛化性与高效性问题研究方案中已经充分阐述

将 Two-tone 编码集成到实际存储系统面临两大挑战：一是支持多样化的擦除模式，二是突破内存访问瓶颈。针对第一个问题，提出了统一擦除-校验映射机制，将所有数据丢失场景归纳为单一解码路径，简化了冗余条件判断。针对内存压力，采用固定窗口分块策略提升缓存命中率，并在寄存器中合并相邻数据块，减少内存访问次数。

主要技术难点包括：

- 泛化解码流程复杂，需针对不同丢失模式设计统一且高效的处理机制。
- 异或运算对初始值要求严格，需高效实现按需初始化，避免全量遍历带来的内存开销。
- 校验块与数据块的访问模式差异大，难以形成统一的高局部性内存访问策略。
- 特殊丢失场景下需结合硬件指令集（如 AVX2）进行特化优化，提升极端场景下的性能。

7.2 解决方案

针对上述难点，拟采取如下解决措施：

- 设计 erasure-parity mapping 结构，实现所有丢失情况的统一抽象，简化解码流程。
- 引入 cache-friendly window 划分，结合“首次访问初始化”策略，提升缓存局部性并降低初始化开销。
- 采用 neighbor merging access 方法，在寄存器层面合并数据块，减少内存访问次数，提升整体吞吐量。

- 针对特殊场景，结合 AVX2 等硬件指令进行特化优化，实现极端情况下的高效解码。
- 持续迭代算法与系统实现，结合实际测试反馈不断完善优化策略。

参考文献

- [1] FORD D, LABELLE F, POPOVICI F I, et al. Availability in Globally Distributed Storage Systems [C] //9th USENIX Symposium on Operating Systems Design and Implementation (OSDI 10), Vancouver, BC : USENIX Association, 2010.
- [2] WEATHERSPOON H, KUBIATOWICZ J D. Erasure Coding Vs. Replication: A Quantitative Comparison [C] //DRUSCHEL P, KAASHOEK F, ROWSTRON A. Peer-to-Peer Systems, Berlin, Heidelberg : Springer Berlin Heidelberg, 2002 : 328-337.
- [3] GHEMAWAT S, GOBIOFF H, LEUNG S-T. The Google File System [C] //Proceedings of the Nineteenth ACM Symposium on Operating Systems Principles, Bolton Landing NY USA : ACM, 2003 : 29-43.
- [4] CALDER B, WANG J, OGUS A, et al. Windows Azure Storage: A Highly Available Cloud Storage Service with Strong Consistency [C] //Proceedings of the Twenty-Third ACM Symposium on Operating Systems Principles, Cascais Portugal : ACM, 2011 : 143-157.
- [5] HUANG C, SIMITCI H, XU Y, et al. Erasure Coding in Windows Azure Storage [C] //2012 USENIX Annual Technical Conference (USENIX ATC 12), Boston, MA : USENIX Association, 2012 : 15-26.
- [6] SHVACHKO K, KUANG H, RADIA S, et al. The Hadoop Distributed File System [C] //2010 IEEE 26th Symposium on Mass Storage Systems and Technologies (MSST), Incline Village, NV, USA : IEEE, 2010 : 1-10.
- [7] CHINIAH A, MUNGUR A. Dynamic Erasure Coding Policy Allocation (DECPA) in Hadoop 3.0 [C] //2019 6th IEEE International Conference on Cyber Security and Cloud Computing (CSCloud)/ 2019 5th IEEE International Conference on Edge Computing and Scalable Cloud (EdgeCom), Paris, France : IEEE, 2019 : 29-33.
- [8] WEIL S A, BRANDT S A, MILLER E L, et al. Ceph: A Scalable, High-Performance Distributed File System [C] //7th USENIX Symposium on Operating Systems Design and Implementation (OSDI 06), Seattle, WA : USENIX Association, 2006.
- [9] WEIL S A. Ceph: Reliable, Scalable, and High-Performance Distributed Storage [D] . Santa Cruz : University of California, 2007.

- [10] REED I S, SOLOMON G. Polynomial Codes Over Certain Finite Fields [J] . Journal of the Society for Industrial and Applied Mathematics, 1960, 8 (2) : 300-304.
- [11] LUBY M, ZUCKERMANK D. An XOR-Based Erasure-Resilient Coding Scheme [J] . Tech Report, Tech. Rep., 1995.
- [12] PLANK J S, SIMMERMAN S, SCHUMAN C D. Jerasure: A Library in C/C++ Facilitating Erasure Coding for Storage Applications - Version 1.2 : CS-08-627 [R] . Knoxville, TN 37996, USA : University of Tennessee, 2008.
- [13] ARSLAN S S, LE H, LANDMAN J, et al. OpenMP and POSIX Threads Implementation of Jerasure 2.0 [C] //2017 IEEE International Black Sea Conference on Communications and Networking (BlackSeaCom), Istanbul, Turkey : IEEE, 2017 : 1-5.
- [14] LIU C, WANG Q, CHU X, et al. G-CRS: GPU Accelerated Cauchy Reed-Solomon Coding [J] . IEEE Transactions on Parallel and Distributed Systems, 2018, 29 (7) : 1484-1498.
- [15] ZHOU T, TIAN C. Fast Erasure Coding for Data Storage: A Comprehensive Study of the Acceleration Techniques [C] //17th USENIX Conference on File and Storage Technologies (FAST 19), Boston, MA : USENIX Association, 2019 : 317-329.
- [16] ZHOU T, TIAN C. Fast Erasure Coding for Data Storage: A Comprehensive Study of the Acceleration Techniques [J] . ACM Transactions on Storage, 2020, 16 (1) : 1-24.
- [17] UEZATO Y. Accelerating XOR-based Erasure Coding Using Program Optimization Techniques [C] //Proceedings of the International Conference for High Performance Computing, Networking, Storage and Analysis, St. Louis Missouri : ACM, 2021 : 1-14.
- [18] NIU T, LYU M, WANG W, et al. Cerasure: Fast Acceleration Strategies For XOR-Based Erasure Codes [C] //2023 IEEE 41st International Conference on Computer Design (ICCD), Washington, DC, USA : IEEE, 2023 : 535-542.
- [19] WANG W, LYU M, NIU T, et al. Fast Acceleration Strategies for XOR-Based Erasure Codes [J] . IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2025, 44 (1) : 331-344.

- [20] GAJALWAR Y, KHILARI S, KULKARNI H, et al. Exploring Data Protection with ISA-L: A Study on Erasure Coding [C] //2024 Asian Conference on Intelligent Technologies (ACOIT), KOLAR, India : IEEE, 2024 : 1-6.
- [21] SUNG C W, GONG X. A ZigZag-Decodable Code with the MDS Property for Distributed Storage Systems [C] //2013 IEEE International Symposium on Information Theory, Istanbul, Turkey : IEEE, 2013 : 341-345.
- [22] DAI M, SUNG C W, WANG H, et al. A New Zigzag-Decodable Code with Efficient Repair in Wireless Distributed Storage [J] . IEEE Transactions on Mobile Computing, 2017, 16 (5) : 1218-1230.
- [23] GONG X, SUNG C W. Zigzag Decodable Codes: Linear-time Erasure Codes with Applications to Data Storage [J] . Journal of Computer and System Sciences, 2017, 89 : 190-208.
- [24] FU X, XIAO Z, YANG S. Overhead-Free In-place Recovery Scheme for XOR-based Storage Codes [C] //2014 IEEE 13th International Conference on Trust, Security and Privacy in Computing and Communications, Beijing, China : IEEE, 2014 : 552-557.
- [25] FU X, XIAO Z, YANG S. Overhead-Free in-Place Recovery and Repair Schemes of XOR-Based Regenerating Codes [C] //2015 IEEE International Symposium on Information Theory (ISIT), Hong Kong, China : IEEE, 2015 : 854-858.
- [26] FU X, YANG S, XIAO Z. Decoding and Repair Schemes for Shift-XOR Regenerating Codes [J] . IEEE Transactions on Information Theory, 2020, 66 (12) : 7371-7386.
- [27] CHENG X, FU X, GUO Y, et al. Successively Solvable Shift-Add Systems — a Graphical Characterization [C] //2021 IEEE International Symposium on Information Theory (ISIT), Melbourne, Australia : IEEE, 2021 : 946-951.
- [28] FU X, WU C, GUO Y, et al. Two-Tone Shift-XOR Storage Codes [C] //2021 IEEE International Symposium on Information Theory (ISIT), Melbourne, Australia : IEEE, 2021 : 2996-3001.
- [29] DAI M, WANG X, WANG H, et al. Bandwidth Overhead-Free Data Reconstruction Scheme for Distributed Storage Code With Low Decoding Complexity [J] . IEEE Access, 2017, 5 : 6824-6832.
- [30] GONG X, HU P, SHUM K W, et al. A Zigzag-Decodable Ramp Secret Sharing Scheme [J] . IEEE Transactions on Information Forensics and Security, 2018, 13 (8) : 1906-1916.

- [31] KABIRIRAD S, SHEIDANI S, ESLAMI Z. An Efficient Ramp Secret Sharing Scheme Based on Zigzag-Decodable Codes [J] . Computer and Knowledge Engineering, 2023 (Online First) .
- [32] CHEN J, SHEN Y, WAN SUNG C. A New Shift-Add Secret Sharing Scheme for Partial Data Protection With Parallel Zigzag Decoding [J] . IEEE Transactions on Information Forensics and Security, 2024, 19 : 10221-10232.
- [33] DAI M, MAO B, GONG X, et al. Zigzag-Division Multiple Access for Wireless Networks With Long and Heterogeneous Delays [J] . IEEE Transactions on Aerospace and Electronic Systems, 2019, 55 (6) : 2822-2835.
- [34] WEI X, XIE X, CHEN R, et al. Characterizing and Optimizing Remote Persistent Memory with RDMA and NVM [C] // 2021 USENIX Annual Technical Conference (USENIX ATC 21), Online : USENIX Association, 2021 : 523-536.
- [35] MAKOVENKO M, CHENG M, TIAN C. Revisiting the Optimization of Cauchy Reed-Solomon Coding Matrix for Fault-Tolerant Data Storage [J] . IEEE Transactions on Computers, 2022, 71 (8) : 1839-1846.